Как правильно писать компараторы

Обо мне

- Юрий Грибов
- Инженер-компиляторщик
- Gmail: tetra2005
- t.me/the real yugr
- https://github.com/yugr
- https://www.linkedin.com/in/yugr/



План доклада

- Что же такое компаратор
- Пример UB
- Аксиоматика компараторов
- Самые частые ошибки
- И средства их обнаружения

Компараторы

- Обобщение operator<
- Функторы-предикаты для сравнения элементов какого-либо типа
- Используются различными алгоритмами и контейнерами стандартной библиотеки для упорядочения/поиска объектов

```
std::sort(begin, end, comp);
std::sort(begin, end); // Используется operator<</pre>
```

Использование компараторов

• Стандартные контейнеры:

```
• std::map, std::multimap
```

• std::set, std::multiset

• Стандартные алгоритмы:

- std::sort, std::stable_sort
- std::binary search
- std::equal_range, std::lower_bound, std::upper_bound
- std::min element, std::max element, std::nth element
- etc.

Пример использования компаратора

Программа работает?

```
$ g++ -g -DSIZE=10 bad.cc && ./a.out
1
2
3
5
7
7
7
8
9
```

Или нет...

```
$ g++ -g -DSIZE=50 bad.cc && ./a.out
1
4
1
9
2
5
...
double free or corruption (out)
Aborted
```

Buffer overflow!

```
$ g++ -g -DSIZE=50 -fsanitize=address -D GLIBCXX SANITIZE VECTOR=1 bad.cc && ./a.out
==143607==ERROR: AddressSanitizer: container-overflow on address 0x611000000108
READ of size 4 at 0x611000000108 thread TO
     #0 0x55fa93254d5c in operator()<__gnu_cxx::__normal_iterator<int*, std::vector<int> >,
gnu cxx:: normal iterator<int*, s\overline{td}::v\overline{e}ctor<\overline{int}> > \overline{log}/usr/include/c++/10/bits/predefined ops.h:156
     #1 0x55fa93255164 in unguarded partition< gnu cxx:: normal iterator<int*, std::vector<int> >,
__gnu_cxx::__ops::_Iter_comp_iter<main()::<lambda(int, int)> > /usr/include/c++/10/bits/stl algo.h:1904
#2 0x55fa9325428b in __unguarded_partition_pivot<__gnu_cxx::__normal_iterator<int*, std::vector<int> >,
__gnu_cxx::__ops::_Iter_comp_iter<main()::<lambda(int, int)> > /usr/include/c++/10/bits/stl_algo.h:1926
#3 0x55fa93253d1f in __introsort_loop<_ gnu_cxx::__normal_iterator<int*, std::vector<int> >, long int,
__gnu_cxx::__ops::_Iter_comp_iter<main()::<lambda(int, int)> > /usr/include/c++/10/bits/stl_algo.h:1958
     #4 0x55fa93253d3d in introsort loop< gnu cxx:: normal iterator<int*, std::vector<int> >, long int,
__gnu_cxx::__ops::_Iter_comp_iter<main()::<lambda(int, int)> > /usr/include/c++/10/bits/stl algo.h:1959
#5 0x55fa93253d3d in __introsort_loop<_ gnu_cxx::__normal_iterator<int*, std::vector<int> >, long int,
__gnu_cxx::__ops::_Iter_comp_iter<main()::<lambda(int, int)> > /usr/include/c++/10/bits/stl_algo.h:1959
     #6 0x55fa93253a6f in sort< gnu cxx:: normal iterator<int*, std::vector<int> >,
gnu cxx:: ops:: Iter \overline{\text{comp}} iter\overline{\text{cmain}}()::\overline{\text{lambda}}(int, int)>>> /usr/include/c++/10/bits/stl algo.h:1974
     #7 0x55fa932537fb in sort< gnu cxx:: normal iterator<int*, std::vector<int> >, main()::<lambda(int, int)> >
/usr/include/c++/10/bits/stl algo.h:4894
     #8 0x55fa932534ca in main /home/yugr/tasks/CppRussia/bad.cc:11
     #9 0x7f9bba05ad09 in libc start main ../csu/libc-start.c:308
     #10 0x55fa93253249 in start (/home/yugr/tasks/CppRussia/a.out+0x2249)
```

Причина ошибки

• Разбиение массива по опорному элементу (основной шаг быстрой сортировки)

Причина ошибки

- Опорный элемент ___pivot выбирается как медиана первого, среднего и последнего элемента массива
- Поэтому при входе в цикл всегда существуют а и b, такие что ___comp (a, __pivot) && __comp (__pivot, b)
- И этот инвариант сохраняется в ходе выполнения внешнего цикла
- Из этого по идее следует условие, гарантирующее отсутствие выхода за границы массива:

```
!__comp(__pivot, a) && !__comp(b, __pivot)
```

Причина ошибки

Для компаратора

```
auto comp = [](int l, int r) { return l <= r; } 

не выполняется условие comp(\_pivot, b) \Rightarrow !comp(b, \_pivot)
в случае l == r.
```

Нарушается необходимый инвариант цикла и просходит переполнение буфера.

Требования к компараторам

Требования к компараторам

- Для избежания ошибок в работе алгоритмов сортировки компараторы должны удовлятворять набору правил (аксиом)
- Правила указаны в стандарте языка: bit.ly/3LpH5Nc



- Нарушение аксиом приводит к Undefined Behavior (аварийные завершения, некорректные результаты, зависания)
- Не специфичны для C++: <u>C</u>, <u>Java</u>, <u>Lua</u>, <u>Swift</u>, <u>JavaScript</u> и <u>Rust</u>

Аксиомы строгого частичного порядка

• Иррефлексивность:

```
!comp(a, a)
```

• Антисимметричность:

```
comp(a, b) \Rightarrow !comp(b, a)
```

• Транзитивность:

```
comp(a, b) && comp(b, c) \Rightarrow comp(a, c)
```

- В алгебре такие компараторы называют *строгими частичными порядками*, а соответствующие множества *частично упорядоченными* (partially ordered)
 - Кратко: ЧУМ или poset

Отношение эквивалентности

• С каждым компаратором связана ещё одна функция ("отношение" в терминах алгебры):

```
bool equiv(T a, T b) {
  return !comp(a, b) && !comp(b, a);
}
```

- Отношение эквивалентности или несравнимости (incomparability)
- Показывает что два элемента "неразличимы" с точки зрения компаратора
- Похоже на оператор равенства, но вообще говоря отличается от operator==

Транзитивность эквивалентности

• Транзитивность эквивалентности:

```
equiv(a, b) && equiv(b, c) \Rightarrow equiv(a, c)
```

- Сортируемое множество можно разбить на группы "равных" элементов
- Эти группы будут вести себя одинаково в сравнениях:
 - Сравнение любого экземпляра группы с другими элементами множества будет давать одинаковый результат независимо от выбора экземпляра

Транзитивность эквивалентности

- Необходимое условие для всех "быстрых" алгоритмов сортировки
 - Why do we need transitivity of equivalence
- Не всем алгоритмам STL требуется транзитивность эквивалентности!
 - Например для std::min/min_element достаточно частичного порядка
 - Но Стандарт требует выполнения четырёх аксиом для всех алгоритмов (вероятно для упрощения)

Strict weak ordering

- Строгий слабый порядок (strict weak ordering)
 - Частичный порядок + транзитивность эквивалентности
- Выдержки из n4868:
 - alg.sorting:
 - For algorithms other than those described in [alg.binary.search], comp shall induce a strict weak ordering on the values.
 - utility.arg.requirements (Cpp17LessThanComparable):
 - < is a strict weak ordering relation

Spaceship-оператор и другие виды порядков в C++20

- Стандарт движется в сторону явного представления понятия порядка в языке
- В C++20 введён новый тип оператор сравнения: operator<=>
 - Сокращает объём кода для реализации всех операторов сравнения (==, !=, <, >, <=, >=)
- Может возвращать значение одного из 3 типов (comparison categories) в зависимости от вида порядка, реализуемого классом:
 - std::partial ordering
 - std::weak ordering
 - std::strong ordering

Семантика comparison categories?

- Можно было бы предположить что наличие категории даёт гарантии о поведении класса, например
 - std::partial ordering класс является частичным порядком?
 - std::weak ordering класс является слабым порядком?
- Но на данный момент это не гарантируется Стандартом
- Выбор той или иной категории не даёт никаких гарантий поведения и служит скорее для документирования
 - <u>Implied meaning of ordering types</u>



Частые ошибки

Частые ошибки: неправильный лексикографический порядок

- Самая частая ошибка при написании компараторов
- Нарушена аксиома антисимметричности:

```
A(100, 2) < A(200, 1) & & \\ A(200, 1) < A(100, 2)
```

```
bool operator<(const A &rhs) {
  if (first < rhs.first)
    return true;

else if (second < rhs.second)
  return true;

else
  return false;
}</pre>
```

Частые ошибки: лексикографический порядок

• Простое исправление:

```
if (first < rhs.first)
  return true;
else if (first == rhs.first && second < rhs.second)
  return true;
else
  return false;</pre>
```

Частые ошибки: лексикографический порядок

- Но лучше:
 - использовать std::tie и встроенный оператор сравнения кортежей:

```
return std::tie(l.first, l.second) <
  std::tie(r.first, r.second);</pre>
```

• (C++20) использовать реализацию operator<=> по умолчанию:

```
auto operator<=>(const SomeClass &) const =
default;
```

Частые ошибки: нестрогий порядок



26/50

Частые ошибки: отрицание строгого порядка не является строгим порядком

• Другая вариация той же ошибки:

```
auto lt = std::less<int>();
auto inv_lt = std::not2(lt);
std::sort(..., inv_lt);
```

- Отрицание строгого порядка является нестрогим порядком (и нарушает аксиому антисимметричности)
- Пример из жизни:
 - Bug hunting fun with std::sort



```
int main() {
  double a[] = {
    100, 5, 3, NAN, 200, 11
  };
  std::sort(&a[0], &a[std::size(a)]);
  for (auto x : a)
    std::cout << x << "\n";
  return 0;
}</pre>
```

```
$ g++ bad.cc && ./a.out
3
5
100
nan
11
200
```

- Типы с плавающей точкой поддерживают специальные значения NaN, которые возникают в результате некорректных вычислений
 - например извлечения корня из отрицательного числа или деления 0/0
- Сравнение с NaN всегда возвращает false, поэтому NaN эквивалентен всем остальным числам
- Это приводит к нарушению транзитивности эквивалентности (4 аксиома):
 - NAN ~ 1.0
 - NAN ~ 2.0
 - Ho HE 1.0 ~ 2.0

• Достаточно перед сортировкой избавиться от NaN'ов с помощью std::partition:

• В случае std::map сделать классс-обёртку над float

Частые ошибки: некорректная обработка специального случая

```
[](std::unique_ptr<SomeClass> a,
    std::unique_ptr<SomeClass> b) {
    if (!a.get())
       return true;
    else if (!b.get())
       return false;
    else
       return *a < *b;
}</pre>
```

Нарушена иррефлексивность и антисимметричность если оба операнда нулевые

Частые ошибки: некорректная обработка специального случая

Общий паттерн ошибки:

```
[](A lhs, A rhs) {
  if (predicate(lhs))
    return true;
  ...
}
```

Частые ошибки: сравнение особых объектов отдельным алгоритмом

• Нарушена транзитивность:

```
A(true, 1, 2) 
A(true, 2, 1)
A(true, 2, 1) 
A(false, 1, 2)
! A(true, 1, 2) 
A(false, 1, 2)
```

- Пример из жизни:
 - GCC Bugzilla #68988



```
class A {
  bool special;
  int x, y;
  bool operator<(A rhs) {
    if (special && rhs.special)
      return x < rhs.x;
    return y < rhs.y;
  }
};</pre>
```

Частые ошибки: сравнение особых объектов отдельным алгоритмом

```
class A {
  bool special;
  int x, y;
  bool operator<(A rhs) {
   if (special != rhs.special)
      return special < rhs.special;
   if (special && rhs.special)
      return x < rhs.x;
  return y < rhs.y;
  }
};</pre>
```

Частые ошибки: сравнение особых объектов отдельным алгоритмом

Общий паттерн ошибки:

```
auto comp = [](Object a, Object b) {
  if (is_special(a) && is_special(b))
    return comp_special(a, b);
  else
    return comp_default(a, b);
}
```

Частые ошибки: приближенные сравнения

```
bool cmp(double a, double b) {
   if (abs(a - b) < eps) return false;
   return a < b;
}</pre>
```

- Программист хотел чтобы "близкие" элементы рассматривались как эквивалентные
- Но при этом нарушил аксиому транзитивности эквивалентности:

```
equiv(0, 0.5 * eps) == true
equiv(0.5 * eps, eps) == true
cmp(0, eps) == false
```

Инструменты

Отладочные средства в тулчейнах: libstdc++

- B libstdc++ с помощью макроса -D_GLIBCXX_DEBUG можно включить дополнительную проверку иррефлексивности
- Она бы нашла ошибку из начала презентации

Отладочные средства в тулчейнах: libc++

• B libc++ с помощью макроса -D_LIBCPP_ENABLE_DEBUG_MODE можно включить проверку асимметричности:

Comparator consistency checks

Libc++ provides some checks for the consistency of comparators passed to algorithms. Specifically, many algorithms such as binary_search, merge, next_permutation, and sort, wrap the user-provided comparator to assert that !comp(y, x) whenever comp(x, y). This can cause the user-provided comparator to be evaluated up to twice as many times as it would be without the debug mode, and causes the library to violate some of the Standard's complexity clauses.

Отладочные средства в тулчейнах

- Обе опции имеют существенные (2х) накладные расходы
- Рекомендуется использовать только для тестирования
- Чекеры компараторов не должны менять алгоритмическую сложность алгоритма O(N*logN)
- И поэтому не могут провести полную проверку корректности
 - Например проверку аксиом транзитивности

SortChecker++

- https://github.com/yugr/sortcheckxx
- Динамический чекер для проверки компараторов в программах на С++
- Перехватывает и проверяет STL API типа std::sort и контейнеры типа std::map
- Основан на source-to-source инструментации (Clang-based)
- 5 ошибок в различных OSS проектах
- TODO: поддержать все релевантные алгоритмы (nth_element, etc.)

SortChecker

- https://github.com/yugr/sortcheck
- Динамический чекер для проверки компараторов в программах на Си
- Перехватывает и проверяет libc API типа qsort и bsearch
- Основан на динамической инструментации (LD_PRELOAD)
- Нашёл 15 ошибок в различных OSS проектах (GCC, Harfbuzz, etc.)

Как использовать SortChecker++

• Вначале инструментируем код:

```
$ sortcheckxx/bin/SortChecker tmp.cc -- -DSIZE=50

std::sort(begin, end, cmp);

cmp, __FILE__, __LINE__);
```

• Скомпилируем и запустим инструментированный код из начала презентации:

```
$ g++ -g -DSIZE=50 -Isortcheckxx/include tmp.cc &&
./a.out
sortcheck: tmp.cc:14: irreflexive comparator at
position 0
Aborted
```

Псевдокод

• Каждый запуск std::sort и аналогичных API предваряется проверками:

```
for x in array
  if comp(x, x)
    error

for x, y in array
  if comp(x, y) != comp(y, x)
    error

for x, y, z in array
  if comp(x, y) && comp(y, z) && !comp(x, z)
    error

for x, y, z in array
  if equiv(x, y) && equiv(y, z) && !equiv(x, z)
    error
```

- Сложность проверок составляет O(N^3)
- Существенно превосходит даже std::sort, не говоря о более быстрых алгоритмах (std::max element, etc.)
- На практике обходится не весь массив, а его небольшое подмножество (20-30 элементов) 45/50

Быстрый алгоритм проверки

- https://github.com/danlark1/quadratic strict weak ordering
- Предложен Д. Кутениным в начале 2023 года
- Идея алгоритма:
 - Предварительно отсортировать массив устойчивым алгоритмом
 - Выделять в отсортированном массиве префиксы эквивалентных элементов
 - И проверять их на транзитивность с оставшейся частью массива
- Снижает сложность до O(N^2) (по прежнему превосходит сложность проверяемых алгоритмов)
- Возможно будет интегрирован в libc++ (<u>D150264</u>) и SortChecker

Что почитать

- Danila Kutenin Changing std::sort at Google's Scale and Beyond
- Jonathan Müller Mathematics behind Comparison

Рекомендации

- Избегайте типичных ошибок в работе
- Включите _GLIBCXX_DEBUG и _LIBCPP_ENABLE_DEBUG_MODE в своём CI
- Примените SortChecker и SortChecker++ к своему коду
 - Сообщения об ошибках и дополнения приветствуются!

Другие типы ошибок в компараторных АРІ

- Неотсортированные массивы в API типа std::binary_search
 - поддерживается в SortChecker/SortChecker++
- Расчёт на определённый порядок сортировки эквивалентных элементов
 - проверяется в отладочной libc++ (-D_LIBCPP_ENABLE_DEBUG_MODE) с помощью рандомизации

Спасибо за внимание!

Частые ошибки: неправильный лексикографический порядок

Примеры:

- https://stackoverflow.com/questions/48455244/bug-in-stdsort
- https://stackoverflow.com/questions/53712873/sorting-a-vector-of-a-custom-class-with-stdsort-causes-a-segmentation-fault
- https://stackoverflow.com/questions/68225770/sorting-vector-of-pair-using-lambda-predicate-crashing-with-memory-corruption
- https://stackoverflow.com/questions/72737018/stdsort-results-in-a-segfault
- https://stackoverflow.com/questions/33547566/strict-weak-ordering-operator-in-c

Частые ошибки: нестрогий порядок

- https://stackoverflow.com/questions/40483971/program-crash-in-stdsort-sometimes-cant-reproduce
- https://stackoverflow.com/questions/65468629/stl-sort-debug-assertion-failed
- https://stackoverflow.com/questions/18291620/why-will-stdsort-crash-if-the-comparison-function-is-not-as-operator
- https://stackoverflow.com/questions/19757210/stdsort-from-algorithm-crashes
- https://stackoverflow.com/questions/64014782/c-program-crashes-when-trying-to-sort-a-vector-of-strings
- https://stackoverflow.com/questions/70869803/c-code-crashes-when-trying-to-sort-2d-vector
- https://stackoverflow.com/questions/67553073/std-sort-sometimes-throws-seqmention-fault

Частые ошибки: некорректная обработка специального случая

• Примеры:

- https://stackoverflow.com/questions/55815423/stdsort-crashes-with-strict-weak-ordering-comparing-with-garbage-values
- https://stackoverflow.com/questions/48972158/crash-in-stdsort-sorting-without-strict-weak-ordering

Частые ошибки: NaN

- Пример:
 - https://stackoverflow.com/questions/9244243/strict-weak-ordering-and-stdsort

Частые ошибки: приближенные сравнения

- Пример:
 - https://stackoverflow.com/questions/68114060/does-using-epsilon-in-comparison-of-floating-point-break-strict-weak-ordering